RMSNorm（均方根层归一化）

RMSNorm（Root Mean Square Layer Normalization）是 LayerNorm 的一种简化变体：**移除均值中心化（re-centering）**，仅保留基于 RMS 的**缩放归一化（re-scaling）**。在效果与 LayerNorm 相当的前提下（部分场景），只做**一次统计量规约、无逐元素减法路径**，计算开销更低；同时保留对输入与权重整体缩放的**re-scaling 不变性**，归一化结果不受尺度影响。凭借低开销与稳定效果，RMSNorm 已被 **LLaMA、Mistral、Qwen 等主流大模型广泛采用**，成为大模型时代最常用的归一化层之一。

论文链接

1. 引言与动机

深层网络训练不稳定的一个来源是**内部协变量偏移**：前置层的参数更新会改变后置层的输入分布，导致梯度尺度不稳、收敛缓慢。归一化层的思路是对每层输入施加一个「尺度标准形」，缓解分布漂移。

LayerNorm 对求和后的输入 $\mathbf{a}$ 同时做中心化与缩放：

$$\mu = \frac{1}{n}\sum_{i=1}^{n} a_i, \qquad \sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(a_i-\mu)^2}, \qquad \mathrm{LN}(\mathbf{a})_i = \frac{a_i-\mu}{\sigma}\, g_i$$

其代价是两次统计量规约：均值 μ 与方差 σ^2 各需一次全局归约。

> 📌 **设计动机**：归一化带来的收益主要由 re-scaling 提供；去除 re-centering 不影响效果，但显著降低计算量。

2. 数学定义与前向计算

定义（RMSNorm）：对求和输入 $\mathbf{a} \in \mathbb{R}^n$，逐元素归一化：

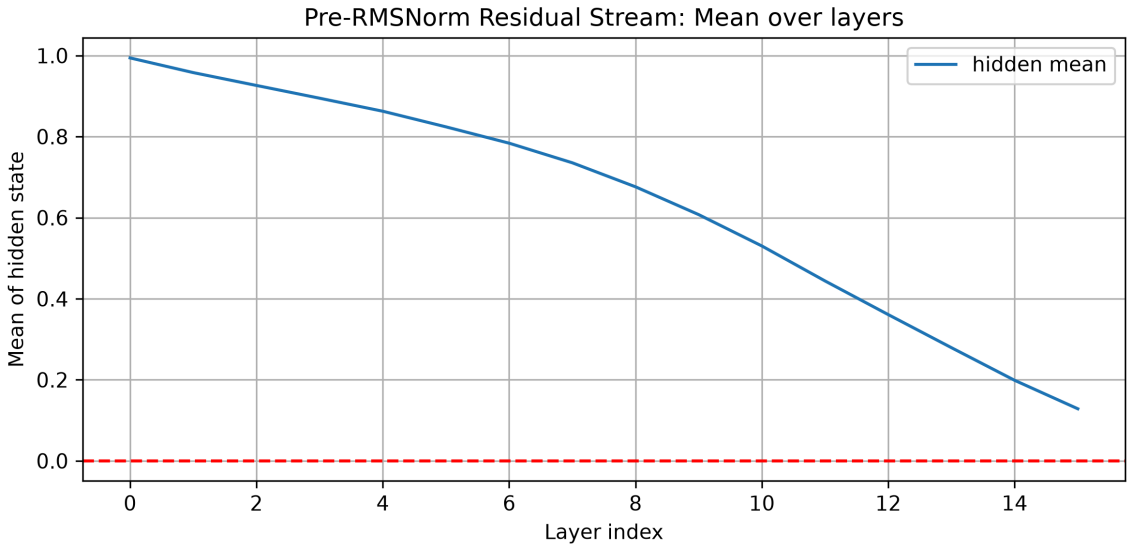
$$\bar{a}_i = \frac{a_i}{\mathrm{RMS}(\mathbf{a})}, \qquad v_i = \bar{a}_i\, g_i, \qquad \mathrm{RMS}(\mathbf{a}) = \sqrt{\frac{1}{n}\sum_{i=1}^{n} a_i^2}$$

$$\mathbf{y} = f(\mathbf{v})$$

其中 $\mathbf{x}$ 为线性层输入，$\mathbf{a} = W\mathbf{x}$ 为求和输入，$\mathbf{g}$ 为可学习 gain（初始化为 1，**经过学习后各维度值可能不同**），$\bar{\mathbf{a}}$ 为归一化输入，$\mathbf{v}$ 为 RMSNorm 的输出。

与 LayerNorm 的关系：当 $\mu = 0$ 时，$\sigma = \mathrm{RMS}(\mathbf{a})$，两者归一化结果逐元素相等。因此 RMSNorm 可视为 LayerNorm 在「输入零均值」假设下的特例；**实际中注意力/线性层输出常近似零均值（即使初始均值不为0）**，故性能损失有限。

前向计算仅含三类可向量化操作：平方求均值、开方、逐元素乘除；不引入额外超参数。



3. 不变性分析

3.1 定理：缩放不变性

设输入 $\mathbf{x}$ 整体缩放 $\delta > 0$，则 $\mathbf{a}' = W(\delta\mathbf{x}) = \delta\mathbf{a}$，归一化输出不变：

$$\mathbf{v}' = \frac{\delta\mathbf{a}}{\mathrm{RMS}(\delta\mathbf{a})} \odot \mathbf{g} = \frac{\delta\mathbf{a}}{\delta\,\mathrm{RMS}(\mathbf{a})} \odot \mathbf{g} = \mathbf{v}$$

权重矩阵 W 整体缩放 δ 同理（此时 $\mathbf{a}' = \delta W\mathbf{x} = \delta\mathbf{a}$）。即 RMSNorm 对输入与权重矩阵的整体 re-scaling 不变。

边界条件：**不变性仅对「整体缩放」成立**——对单个权重向量或部分维度做不同倍率缩放不成立；对平移（re-centering）也不成立，这是与 LayerNorm 的实质差异。

3.2 与 LayerNorm 的不变性对照

方法	权重矩阵 re-centering	权重矩阵 re-scaling	数据集 re-scaling
LayerNorm	✓ 不变	✓ 不变	✓ 不变
RMSNorm	✗	✓ 不变	✓ 不变

> 💡 **易错点**：缩放不变性指整体 re-scaling；LayerNorm 额外具备 re-centering 不变性（对平移不敏感），RMSNorm 不具备——回答「两者差异」时须区分 re-centering 与 re-scaling 两个维度。

4. 梯度推导

设输入向量 $\mathbf{a} \in \mathbb{R}^n$，定义 RMS 归一化因子

$$r = \mathrm{RMS}(\mathbf{a}) = \sqrt{\frac{1}{n}\sum_{k=1}^{n} a_k^2}$$

归一化向量

$$\bar{\mathbf{a}} = \mathbf{a}/r$$

令激活输入为逐元素乘积

$$\mathbf{v} = \bar{\mathbf{a}} \odot \mathbf{g}$$

其中 $\mathbf{g} \in \mathbb{R}^n$ 为可学习逐元素增益参数，$\odot$ 表示哈达玛积。记上游梯度 $\partial L/\partial \mathbf{v}$。

4.1 损失 L 对增益 g 的梯度

由 $v_i = \bar{a}_i g_i$，链式法则给出

$$\frac{\partial L}{\partial g_j} = \sum_i \frac{\partial L}{\partial v_i}\frac{\partial v_i}{\partial g_j} = \frac{\partial L}{\partial v_j}\,\bar{a}_j$$

写成向量形式

$$\frac{\partial L}{\partial \mathbf{g}} = \frac{\partial L}{\partial \mathbf{v}} \odot \bar{\mathbf{a}} = \frac{\partial L}{\partial \mathbf{v}} \odot \frac{\mathbf{a}}{r}$$

4.2 损失 L 对增益 a 的梯度 和 R矩阵

先求归一化算子的雅可比分量。由 $\bar{a}_i = a_i/r$ 以及 $\partial r/\partial a_j = a_j/(nr)$，

$$\frac{\partial \bar{a}_i}{\partial a_j} = \frac{\delta_{ij}}{r} - \frac{a_i a_j}{nr^3}$$

结合 $v_i = g_i \bar{a}_i$，有 $\partial v_i/\partial a_j = g_i \cdot \partial \bar{a}_i/\partial a_j$。代入链式法则：

$$\frac{\partial L}{\partial a_j} = \sum_i \frac{\partial L}{\partial v_i}\frac{\partial v_i}{\partial a_j} = \sum_i \left(g_i \frac{\partial L}{\partial v_i}\right)\left(\frac{\delta_{ij}}{r} - \frac{a_i a_j}{nr^3}\right)$$

引入辅助梯度向量 $\mathbf{d} = \mathbf{g} \odot \partial L/\partial \mathbf{v}$，则

$$\frac{\partial L}{\partial a_j} = \frac{d_j}{r} - \frac{a_j}{nr^3}\left(\mathbf{a}^\top \mathbf{d}\right)$$

整理为向量形式并提取公因子：

$$\frac{\partial L}{\partial \mathbf{a}} = \frac{1}{r}\left(\mathbf{I} - \frac{\mathbf{a}\mathbf{a}^\top}{nr^2}\right)\mathbf{d}$$

记归一化雅可比矩阵

$$R = \frac{1}{\mathrm{RMS}(\mathbf{a})}\left(\mathbf{I} - \frac{\mathbf{a}\mathbf{a}^\top}{n\,\mathrm{RMS}(\mathbf{a})^2}\right)$$

最终梯度写成紧凑形式：

$$\frac{\partial L}{\partial \mathbf{a}} = R\,\mathbf{d}, \qquad \mathbf{d} = \mathbf{g} \odot \frac{\partial L}{\partial \mathbf{v}}$$

4.3 L对W求偏导

设线性变换 $\mathbf{a} = W\mathbf{x}$，其中 $W \in \mathbb{R}^{n\times m}$，输入向量 $\mathbf{x} \in \mathbb{R}^m$，输出 $\mathbf{a} \in \mathbb{R}^n$。我们已经求得 $\partial L/\partial \mathbf{a} \in \mathbb{R}^n$，利用矩阵–向量链式法则求 $\partial L/\partial W$。

对于标量损失 L，矩阵梯度的分量定义为

$$\left(\frac{\partial L}{\partial W}\right)_{ij} = \frac{\partial L}{\partial W_{ij}}$$

由 $\mathbf{a} = W\mathbf{x}$，分量形式 $a_i = \sum_{k=1}^{m} W_{ik}x_k$，于是

$$\frac{\partial a_i}{\partial W_{ij}} = x_j$$

链式法则：

$$\frac{\partial L}{\partial W_{ij}} = \sum_{k=1}^{n} \frac{\partial L}{\partial a_k}\frac{\partial a_k}{\partial W_{ij}} = \frac{\partial L}{\partial a_i}\,x_j$$

该分量关系恰好对应外积：

$$\frac{\partial L}{\partial W} = \frac{\partial L}{\partial \mathbf{a}}\,\mathbf{x}^{\top}$$

这是深度学习线性层反向传播的标准形式。

4.4 数值验证

设 $\mathbf{a} = [3,4]^{\top}$、$\mathbf{g} = [1,1]^{\top}$、$\partial L/\partial \mathbf{v} = [1,1]^{\top}$、$\mathbf{x} = [1,2]^{\top}$（$\mathbf{a} = W\mathbf{x}$）：

1. 归一化：

$$\bar{\mathbf{a}} = \frac{\mathbf{a}}{\mathrm{RMS}(\mathbf{a})} = \frac{[3,4]^{\top}}{3.5355} = [0.8485,\ 1.1314]^{\top}$$

2. R 矩阵：

$$R = \frac{1}{\mathrm{RMS}(\mathbf{a})}\left(I - \frac{\mathbf{a}\mathbf{a}^{\top}}{n\,\mathrm{RMS}(\mathbf{a})^2}\right) = \begin{bmatrix} 0.1810 & -0.1357 \\ -0.1357 & 0.1018 \end{bmatrix}$$

3. $\partial L/\partial \mathbf{g}$：

$$\frac{\partial L}{\partial \mathbf{g}} = \frac{\partial L}{\partial \mathbf{v}} \odot \bar{\mathbf{a}} = [1,1]^{\top} \odot [0.8485,\ 1.1314]^{\top} = [0.8485,\ 1.1314]^{\top}$$

4. $\partial L/\partial \mathbf{a}$：

$$\mathbf{d} = [1,1]^{\top}$$

$$\frac{\partial L}{\partial \mathbf{a}} = R\,\mathbf{d} = [0.0453,\ -0.0339]^\top$$

5. $\partial L/\partial W$：

$$\frac{\partial L}{\partial W} = \frac{\partial L}{\partial \mathbf{a}}\,\mathbf{x}^\top = \begin{bmatrix} 0.0453 & 0.0906 \\ -0.0339 & -0.0678 \end{bmatrix}$$

三个验证点：

- R 对称（步骤 2 副对角线相等）；
- 梯度尺度被 $\frac{1}{r} \approx 0.2828$ 压缩（步骤 4 相对上游梯度 $[1,1]^\top$ 大幅缩小）；
- 步骤 5 按列拉直为 $[0.0453, -0.0339, 0.0906, -0.0678]^\top$，与克罗内克积求和形式的结果一致。

4.5 隐式学习率调节

输入或权重矩阵整体缩放 δ 时，梯度中的归一化矩阵同步缩小：

$$R' = \frac{R}{\delta}$$

即**梯度尺度与输入/权重的 RMS 成反比**：权重矩阵范数偏大时，梯度被自动压小；范数偏小时梯度相对放大。其效果等价于隐式的学习率自适应（implicit learning rate adaptation），实验观测亦显示梯度尺度与 RMS 的负相关关系。

> 📌 **重点**：$R' = \frac{R}{\delta}$ 中的 $\frac{1}{\delta}$ 是「隐式学习率」的数学来源——结构本身提供了梯度缩放，无需显式归一化梯度或调整学习率。

5. 计算复杂度与工程实现

5.1 计算开销对比

维度	LayerNorm	RMSNorm
统计量约简次数	2（均值 + 方差）	1（$\mathbf{a}^2$ 的均值）
逐元素减法	有（$\mathbf{a} - \mu$）	无
可学习参数	$\mathbf{g}, \mathbf{b}$	$\mathbf{g}$
GPU 全局归约	2 次	1 次

归一化层是逐元素操作（$O(H)$），在 LLM 每层总计算量（$O(H^2)$）中占比极小（约万分之一量级），因此 RMSNorm 少一次统计量归约、省去 $\mathbf{a} - \mu$ 减法路径，在**计算量**上的节省有限；真正的收

益在工程层面。

并行训练中，统计量归约是跨设备集合通信点：LayerNorm 每层 2 次全局归约（均值、方差），RMSNorm 仅 1 次——少一次归约即少一次通信与同步，**通信过程也能节省成本**；再叠加省去减法路径带来的内存带宽节省，规模与并行度越大，收益越明显。

5.2 数值稳定性

工程实现通常在 RMS 分母加 ε 防止除零：$r = \sqrt{\mathrm{mean}(\mathbf{a}^2) + \varepsilon}$（$\varepsilon$ 属实现惯例）。

5.3 代码实现（PyTorch 风格）

RMSNorm 前向 + 反向（含线性层 W 梯度），与正文公式一一对应

```python
import torch

def rmsnorm_forward(a, g, eps=1e-6):
    """
    RMSNorm + per-element gain 前向
    Args:
        a: (..., n) 输入向量，最后一维做归一化
        g: (n,) 可学习逐元素增益
        eps: 数值稳定项
    Returns:
        v: 激活输入，(..., n)
        cache: 用于反向的缓存 (a, abar, rms, g)
    """
    rms = torch.sqrt(a.pow(2).mean(dim=-1, keepdim=True) + eps)
    abar = a / rms
    v = abar * g
    return v, (a, abar, rms, g)

def rmsnorm_backward(dv, cache):
    """
    RMSNorm + gain 反向，返回 grad_a, grad_g
    Args:
        dv: ∂L/∂v, (..., n) 上游梯度
        cache: 前向缓存
    Returns:
        grad_a: ∂L/∂a, (..., n)
        grad_g: ∂L/∂g, (n,) 沿所有批量维度规约求和
    """
    a, abar, rms, g = cache
    n = a.shape[-1]
    d = g * dv  # d = g ⊙ ∂L/∂v
    inner = (abar * d).sum(dim=-1, keepdim=True) / n
    grad_a = (d - abar * inner) / rms
```

```
    grad_g = (dv * abar).reshape(-1, n).sum(dim=0)
    return grad_a, grad_g

def linear_backward(grad_a, x):
    """
    线性层反向: a = W @ x (batch 版 a = x @ W.T), ∂L/∂W = grad_a^T @ x
    这里约定: x: (..., m), a: (..., n), W: (n, m)
    grad_a: ∂L/∂a, (..., n)
    x: (..., m)
    return ∂L/∂W: (n, m)
    """
    return torch.einsum("...n,...m->nm", grad_a, x)
```

代码块

```
===== 前向结果 =====
a          = tensor([3., 4.])
rms        = 3.5355
abar       = tensor([0.8485, 1.1314])
v          = tensor([0.8485, 1.1314])

===== RMSNorm 反向梯度 =====
∂L/∂g      = tensor([0.8485, 1.1314])
∂L/∂a      = tensor([ 0.0453, -0.0339])

===== 线性层权重梯度 ∂L/∂W =====
tensor([[ 0.0453,  0.0905],
        [-0.0339, -0.0679]])

===== vec(∂L/∂W) (列主序) =====
tensor([ 0.0453,  0.0905, -0.0339, -0.0679])

===== Autograd 校验（验证解析梯度正确性） =====
autograd ∂L/∂a = tensor([ 0.0453, -0.0339])
autograd ∂L/∂g = tensor([0.8485, 1.1314])
```

6. 附录

本章节补充正文 4.3 节克罗内克积形式的相关细节，采用 vec 算子与克罗内克积进行统一的符号推导与数值核验。约定：$\mathrm{vec}(\cdot)$ 为**列主序向量化算子**，将矩阵按列依次堆叠为列向量；克罗内克积定义为，对矩阵 $A \in \mathbb{R}^{m\times n}$ 、$B \in \mathbb{R}^{p\times q}$ ，$A \otimes B \in \mathbb{R}^{mp\times nq}$ 是分块矩阵，把 A 的每个元素 a_{ij} 替换为子块 $a_{ij}B$ ：

$$A \otimes B = \begin{bmatrix} a_{11}B & \cdots & a_{1n}B \\ \vdots & \ddots & \vdots \\ a_{m1}B & \cdots & a_{mn}B \end{bmatrix}.$$

两个核心恒等式贯穿推导：

$$\operatorname{vec}\left(\mathbf{u}\mathbf{v}^{\top}\right) = \mathbf{v} \otimes \mathbf{u}, \qquad \operatorname{vec}(W\mathbf{x}) = \left(\mathbf{x}^{\top} \otimes I_n\right) \operatorname{vec}(W).$$

引入 vec 算子的目的：$\partial \mathbf{a}/\partial W$ 是向量对矩阵的三阶雅可比张量，无法直接套用向量–向量链式法则；将矩阵参数 W 拉直为长向量 $\operatorname{vec}(W)$，即可把三阶张量转化为标准二维雅可比矩阵，在向量空间中完成链式求导。

沿用前文测试配置：$\mathbf{a} = [3,4]^{\top}$, $n = 2$, $R = \begin{bmatrix} 0.1810 & -0.1357 \\ -0.1357 & 0.1018 \end{bmatrix}$，
$\mathbf{g} = [1,1]^{\top}$, $\partial L/\partial \mathbf{v} = [1,1]^{\top}$, $\mathbf{x} = [1,2]^{\top}$。记辅助梯度 $\mathbf{d} = \mathbf{g} \odot \partial L/\partial \mathbf{v} = [1,1]^{\top}$，于是

$$\frac{\partial L}{\partial \mathbf{a}} = R\mathbf{d} = \begin{bmatrix} 0.0453 \\ -0.0339 \end{bmatrix}.$$

构造矩阵 $M = \operatorname{diag}(\mathbf{d})R$，本例中 $\operatorname{diag}(\mathbf{d}) = I_2$，故 $M = R$。计算 $\mathbf{x}^{\top} \otimes M$：

$$\mathbf{x}^{\top} \otimes R = \begin{bmatrix} 1 \cdot R & 2 \cdot R \end{bmatrix} = \begin{bmatrix} 0.1810 & -0.1357 & 0.3620 & -0.2714 \\ -0.1357 & 0.1018 & -0.2714 & 0.2036 \end{bmatrix}.$$

记号 $[\cdot]_i$ 表示取矩阵第 i 行，对所有行求和：

$$\sum_{i=1}^{n} \left[\mathbf{x}^{\top} \otimes M\right]_i = \begin{bmatrix} 0.1810 & -0.1357 & 0.3620 & -0.2714 \end{bmatrix} + \begin{bmatrix} -0.1357 & 0.1018 & -0.2714 & 0.2036 \end{bmatrix} = \begin{bmatrix} 0.0453 & -0.0339 & 0.0906 & -0.0678 \end{bmatrix}.$$

将结果转置为列向量，即为 $\operatorname{vec}\left(\partial L/\partial W\right)$，即

$$\sum_{i=1}^{n} \left[\mathbf{x}^{\top} \otimes \left(\operatorname{diag}(\mathbf{d})R\right)\right]_i = \operatorname{vec}\left(\frac{\partial L}{\partial W}\right).$$

接下来基于 vec 算子执行链式推导。由 $\mathbf{a} = W\mathbf{x}$，使用向量化恒等式：

$$\operatorname{vec}(\mathbf{a}) = \left(\mathbf{x}^{\top} \otimes I_n\right) \operatorname{vec}(W).$$

记拉直后的参数向量 $\boldsymbol{\theta}_W = \operatorname{vec}(W)$，对应的雅可比矩阵为

$$\frac{\partial \operatorname{vec}(\mathbf{a})}{\partial \boldsymbol{\theta}_W} = \mathbf{x}^{\top} \otimes I_n.$$

应用向量链式法则：

$$\frac{\partial L}{\partial \boldsymbol{\theta}_W} = \left(\frac{\partial \operatorname{vec}(\mathbf{a})}{\partial \boldsymbol{\theta}_W}\right)^{\top} \frac{\partial L}{\partial \mathbf{a}}.$$

利用克罗内克积转置性质 $(A \otimes B)^{\top} = A^{\top} \otimes B^{\top}$ 以及 $I_n^{\top} = I_n$，得到

$$\left(\mathbf{x}^{\top}\otimes I_n\right)^{\top}=\mathbf{x}\otimes I_n.$$

于是

$$\frac{\partial L}{\partial \mathrm{vec}(W)}=\left(\mathbf{x}\otimes I_n\right)\frac{\partial L}{\partial \mathbf{a}}.$$

代入 $\partial L/\partial \mathbf{a}=R\mathbf{d}$，$\mathbf{d}=\mathbf{g}\odot \partial L/\partial \mathbf{v}$，最终建立正文给出的克罗内克积求和形式：

$$\frac{\partial L}{\partial \mathrm{vec}(W)}=\mathbf{x}\otimes\left(R\left(\mathbf{g}\odot\frac{\partial L}{\partial \mathbf{v}}\right)\right)=\sum_{i=1}^{n}\left[\mathbf{x}^{\top}\otimes\left(\mathrm{diag}\left(\mathbf{g}\odot\frac{\partial L}{\partial \mathbf{v}}\right)R\right)\right]_i$$

代入数值核验：$\mathbf{x}=[1,2]^{\top}$，$\partial L/\partial \mathbf{a}=[0.0453,-0.0339]^{\top}$，

$$\left(\mathbf{x}\otimes I_2\right)\frac{\partial L}{\partial \mathbf{a}}=\begin{bmatrix}x_1\cdot\partial L/\partial a_1\\ x_1\cdot\partial L/\partial a_2\\ x_2\cdot\partial L/\partial a_1\\ x_2\cdot\partial L/\partial a_2\end{bmatrix}=\begin{bmatrix}0.0453\\ -0.0339\\ 0.0906\\ -0.0678\end{bmatrix}.$$

该结果与前述克罗内克积行求和结果完全一致，即为 $\mathrm{vec}(\partial L/\partial W)$。该 vec 形式适合高阶雅可比、Hessian 与扰动理论的代数推演；推导全程在拉直后的向量空间中使用标准向量链式法则，规避三阶张量的显式表达。